گزارش فاز اول تحلیل داده

تحلیل سفرهای درخواستی نیویورک

High Volume FHV

داده‌های سال‌های 2024 و 2025

نسخهٔ 1.25.34

فهرست مطالب

1 صورت‌بندی مسئله 3
1.1 پیش‌بینی زمان انتظار مسافر 3
1.2 رابطهٔ درآمد ناحیه با زمان انتظار 3
1.3 بازهٔ زمانی تحلیل 3
2 شناخت منشأ داده 4
2.1 منبع و انتشار داده 4
2.2 انتخاب مجموعه‌داده 4
2.3 نمونه و واحد مشاهده 4
2.4 محاسبهٔ زمان انتظار 4
2.5 فرهنگ داده‌ها 5
3 ممیزی ساختار داده 8
3.1 زمان‌های سفر 8
3.2 ناحیه‌های سفر 8
3.3 شناسه‌های سرویس و مرکز 9
3.4 مدت، مسافت و کرایهٔ پایه 9
3.5 نشانگرهای سفر 9
3.6 عوارض، مالیات و مبالغ تکمیلی 10
3.7 ستون‌های نمونه‌گیری 10
4 ممیزی کیفیت 11
4.1 متغیرهای اصلی 11
4.2 زمان انتظار 11
4.3 متغیرهای تحلیل اکتشافی 11
5 تحلیل اکتشافی تک‌متغیره 12
5.1 آمار توصیفی 12
5.2 توزیع‌ها در نمونهٔ مرجع با 10,000 ردیف در ماه 13
5.3 توزیع‌ها در نمونهٔ کوچک‌تر با 5,000 ردیف در ماه 14
5.4 ارزیابی کفایت اندازهٔ نمونه 15
6 تحلیل اکتشافی چندمتغیره 16
6.1 روابط زمان انتظار 16
6.2 ممیزی زمان سفر 17
6.3 سازگاری متغیرهای سفر 18
6.4 الگوهای مکانی سفر 19
6.4.1 ساخت نمای مکانی اولیه 19
6.4.2 نقشه‌های مبدأ و مقصد 20
6.4.3 زمان سوارشدن به تفکیک گروه مبدأ 23
7 تعریف خطر نشت اطلاعات 24
8 تعریف خط مبنا 24
9 سه سؤال اولیه و انتخاب سؤال نهایی 25
9.1 تخصیص رانندگان میان ناحیه‌ها 25
9.2 فرصت افزایش سهم بازار HVFHV 25
9.3 پیش‌بینی زمان انتظار مسافر 25

1 صورت‌بندی مسئله

1.1 پیش‌بینی زمان انتظار مسافر

واحد پیش‌بینی، یک سفر High Volume FHV است. مدل در لحظهٔ ثبت درخواست، زمان انتظار تا سوارشدن مسافر را بر حسب دقیقه برآورد می‌کند. انتظار مشاهده‌شده از اختلاف دو زمان به‌دست می‌آید.

pickup_datetime − request_datetime

برای نمونه، اگر درخواست ساعت 18:05 ثبت شود و مسافر ساعت 18:12 سوار شود، زمان انتظار 7 دقیقه است.

در فایل‌های عمومی سفر، فیلدی برای زمان پذیرش درخواست توسط راننده وجود ندارد. برای تفکیک زمان انتظار تا پذیرش از فاصلهٔ پذیرش تا سوارشدن، به زمان پذیرش نیاز است. بنابراین هدف پیش‌بینی، کل فاصلهٔ ثبت درخواست تا سوارشدن است.

زمان ثبت درخواست و ناحیه‌های مبدأ و مقصد، ورودی‌های پیشنهادی‌اند. شرط استفاده از این ورودی‌ها در بخش 7 آمده است. یک مدل مشترک می‌تواند شناسهٔ ناحیه را به‌عنوان ورودی بگیرد. در پیش‌بینی میانهٔ انتظار برای یک بازهٔ آینده، واحد پیش‌بینی یک ناحیه در یک بازهٔ زمانی است.

1.2 رابطهٔ درآمد ناحیه با زمان انتظار

هدف، بررسی تفاوت معنادار زمان انتظار میان نواحی مبدأ کم‌درآمد و پردرآمد است. برای این مقایسه، دادهٔ درآمد در سطح ناحیه به رکوردهای سفر پیوند داده می‌شود. برای نمونه، می‌توان میانهٔ انتظار و سهم انتظارهای بیش از 10 دقیقه را برای سفرهای یک شرکت در ساعت‌های مشابه مقایسه کرد. اندازهٔ اختلاف در کنار معناداری آماری گزارش می‌شود تا اهمیت عملی آن روشن شود.

این مقایسه بر زمان‌های انتظار مشاهده‌شده استوار است و می‌تواند مستقل از مدل پیش‌بینی انجام شود. دامنهٔ هر دو مسئله، درخواست‌هایی است که به سفر ثبت‌شده منجر شده‌اند.

1.3 بازهٔ زمانی تحلیل

در دورهٔ حاد همه‌گیری کووید، تعداد سفرها کاهش یافت و پراکندگی جغرافیایی آن‌ها تغییر کرد. در مقایسه با دورهٔ پیش از همه‌گیری نیز رواج بیشتر دورکاری و کار ترکیبی، الگوی رفت‌وآمد به محل کار را تغییر داد. به همین دلیل، برای بررسی الگوهای اخیر سفر و آموزش مدل پیش‌بینی، داده‌های High Volume FHV در سال‌های 2024 و 2025 مبنا قرار گرفت.

گزارش اثر کووید بر سفرها، NYC TLC

گزارش دورکاری پس از همه‌گیری، دفتر حسابرس نیویورک

در بررسی اولیه، برآورد حجم سفر و میانهٔ زمان انتظار در این دو سال به هم نزدیک‌اند. تحلیل اکتشافی این فاز به همین بازه محدود شد. در فازهای بعد می‌توان سال‌های دیگری را هم برای سنجش پایداری نتایج و ارزیابی عملکرد مدل در دوره‌های زمانی متفاوت بررسی کرد.

2 شناخت منشأ داده

2.1 منبع و انتشار داده

ارائه‌دهندگان دارای مجوز، اطلاعات سفرها را ثبت می‌کنند و به کمیسیون تاکسی و لیموزین نیویورک، NYC TLC، می‌فرستند. کمیسیون فایل‌های Parquet را به تفکیک ماه و نوع سرویس منتشر می‌کند. فایل هر ماه معمولاً حدود دو ماه بعد منتشر می‌شود تا ارائه‌دهندگان فرصت تکمیل و ارسال داده‌ها را داشته باشند.

صفحهٔ رسمی داده‌های سفر NYC TLC

2.2 انتخاب مجموعه‌داده

FHV مخفف For-Hire Vehicle است. برای سفر با این خودروها، مسافر درخواست خود را نزد یک سرویس ثبت می‌کند. کمیسیون سفرهای ارائه‌دهندگان پرحجم را در فایل‌های High Volume FHV و سفرهای سایر ارائه‌دهندگان این دسته را در فایل‌های FHV منتشر می‌کند.

High Volume FHV مجموعه‌دادهٔ اصلی پروژه است. این دسته در آمار ماهانهٔ سال‌های 2024 و 2025 بیشترین تعداد سفر را دارد و هر دو زمان لازم برای محاسبهٔ انتظار را ثبت می‌کند. در این بازه، میانگین روزانه با وزن‌دهی به ماه‌ها بر اساس تعداد روزهایشان برای High Volume FHV برابر 660,820، برای FHV غیرپرحجم 63,255 و برای تاکسی سبز 1,687 سفر است.

Green Taxi به‌دلیل تعداد بسیار کمتر سفرها از تحلیل کنار گذاشته شد. فایل **FHV** هم سفرهای کمتری دارد و چون زمان درخواست در آن ثبت نمی‌شود، برای تحلیل انتظار کاربرد ندارد. شکل 3 ستون‌های این فایل را نشان می‌دهد.

Yellow Taxi برای مقایسهٔ متغیرهای مشترک کاربرد دارد. برای نمونه، مقایسهٔ توزیع مسافت نشان می‌دهد سفرهای کوتاه و بلند در هر مجموعه چقدر رایج‌اند و کدام الگوها در مقایسه با توزیع مرجع کم‌رخدادند.

آمار ماهانهٔ سفرها، NYC TLC

2.3 نمونه و واحد مشاهده

از فایل هر ماه High Volume FHV در سال‌های 2024 و 2025، 10,000 سفر نمونه‌گیری شد. واحد مشاهده، یک سفر ثبت‌شده است.

2.4 محاسبهٔ زمان انتظار

در فایل High Volume FHV، ستون `request_datetime` زمان ثبت درخواست مسافر را نشان می‌دهد.

ستون `pickup_datetime` زمان سوارشدن او را ثبت می‌کند. برای درخواست‌هایی که به سفر ثبت‌شده منجر شده‌اند، زمان انتظار از تفریق زمان درخواست از زمان سوارشدن به دست می‌آید.

مسافر Yellow Taxi می‌تواند در خیابان به راننده علامت دهد یا از طریق اپلیکیشن درخواست سفر کند. فایل عمومی این سرویس زمان روشن و خاموش‌شدن تاکسی‌متر را به‌عنوان شروع و پایان سفر ثبت می‌کند. این فایل ستون زمان درخواست ندارد، بنابراین محاسبهٔ زمان انتظار با همین روش ممکن نیست. شکل‌های 1 و 2 ستون‌های دو مجموعه را نشان می‌دهند.

راهنمای E-Hail برای تاکسی‌ها، NYC TLC

2.5 فرهنگ داده‌ها

شکل 1. فرهنگ دادهٔ سفرهای High Volume FHV

Field Name	Description
hvfhs_license_num	The TLC license number of the HVFHS base or business. As of September 2019, the HVFHS licensees are the following: • HV0002: Juno • HV0003: Uber • HV0004: Via • HV0005: Lyft
dispatching_base_num	The TLC Base License Number of the base that dispatched the trip.
originating_base_num	Base number of the base that received the original trip request.
request_datetime	Date/time when passenger requested to be picked up.
on_scene_datetime	Date/time when driver arrived at the pick-up location (Accessible Vehicles-only).
pickup_datetime	The date and time of the trip pick-up.
dropoff_datetime	The date and time of the trip drop-off.
PULocationID	TLC Taxi Zone in which the trip began.
DOLocationID	TLC Taxi Zone in which the trip ended.
trip_miles	Total miles for passenger trip.
trip_time	Total time in seconds for passenger trip.
base_passenger_fare	Base passenger fare before tolls, tips, taxes, and fees.
tolls	Total amount of all tolls paid in trip.
bcf	Total amount collected in trip for Black Car Fund.
sales_tax	Total amount collected in trip for NYS sales tax.
congestion_surcharge	Total amount collected in trip for NYS congestion surcharge.
airport_fee	$2.50 for both drop off and pick up at LaGuardia, Newark, and John F. Kennedy airports.
tips	Total amount of tips received from passenger.
driver_pay	Total driver pay (not including tolls or tips and net of commission, surcharges, or taxes).
shared_request_flag	Did the passenger agree to a shared/pooled ride, regardless of whether they were matched? (Y/N)
shared_match_flag	Did the passenger share the vehicle with another passenger who booked separately at any point during the trip? (Y/N)
access_a_ride_flag	Was the trip administered on behalf of the Metropolitan Transportation Authority (MTA)? (Y/N)
wav_request_flag	Did the passenger request a wheelchair-accessible vehicle (WAV)? (Y/N)
wav_match_flag	Did the trip occur in a wheelchair-accessible vehicle (WAV)? (Y/N)
cbd_congestion_fee	Per-trip charge for MTA's Congestion Relief Zone starting Jan. 5, 2025.

راهنما. فیلدهای `request_datetime` و `pickup_datetime` به‌ترتیب زمان درخواست و سوارشدن‌اند. اختلاف این دو زمان مبنای محاسبهٔ انتظار است.

منبع تصویر فرهنگ دادهٔ سفرهای High Volume FHV، NYC TLC

شکل 2. فرهنگ دادهٔ سفرهای Yellow Taxi

Field Name	Description
VendorID	A code indicating the TPEP provider that provided the record. 1 = Creative Mobile Technologies, LLC 2 = Curb Mobility, LLC 6 = Myle Technologies Inc 7 = Helix
tpep_pickup_datetime	The date and time when the meter was engaged.
tpep_dropoff_datetime	The date and time when the meter was disengaged.
passenger_count	The number of passengers in the vehicle.
trip_distance	The elapsed trip distance in miles reported by the taximeter.
RatecodeID	The final rate code in effect at the end of the trip. 1 = Standard rate 2 = JFK 3 = Newark 4 = Nassau or Westchester 5 = Negotiated fare 6 = Group ride 99 = Null/unknown
store_and_fwd_flag	This flag indicates whether the trip record was held in vehicle memory before sending to the vendor, aka “store and forward,” because the vehicle did not have a connection to the server. Y = store and forward trip N = not a store and forward trip
PULocationID	TLC Taxi Zone in which the taximeter was engaged.
DOLocationID	TLC Taxi Zone in which the taximeter was disengaged.
payment_type	A numeric code signifying how the passenger paid for the trip. 0 = Flex Fare trip 1 = Credit card 2 = Cash 3 = No charge 4 = Dispute 5 = Unknown 6 = Voided trip
fare_amount	The time-and-distance fare calculated by the meter. For additional information on the following columns, see https://www.nyc.gov/site/tlc/passengers/taxi-fare.page
extra	Miscellaneous extras and surcharges.
mta_tax	Tax that is automatically triggered based on the metered rate in use.
tip_amount	Tip amount – This field is automatically populated for credit card tips. Cash tips are not included.
tolls_amount	Total amount of all tolls paid in trip.
improvement_surcharge	Improvement surcharge assessed trips at the flag drop. The improvement surcharge began being levied in 2015.
total_amount	The total amount charged to passengers. Does not include cash tips.
congestion_surcharge	Total amount collected in trip for NYS congestion surcharge.
airport_fee	For pick up only at LaGuardia and John F. Kennedy Airports.
cbd_congestion_fee	Per-trip charge for MTA's Congestion Relief Zone starting Jan. 5, 2025.

راهنما. فیلدهای `tpep_pickup_datetime` و `tpep_dropoff_datetime` زمان روشن و خاموش‌شدن تاکسی‌متر را مشخص می‌کنند. شناسه‌های مکانی نیز ناحیهٔ همین دو رویداد را نشان می‌دهند.
منبع تصویر فرهنگ دادهٔ سفرهای Yellow Taxi، NYC TLC

شکل 3. فرهنگ دادهٔ سفرهای FHV

Field Name	Description
dispatching_base_num	The TLC Base License Number of the base that dispatched the trip.
pickup_datetime	The date and time of the trip pick-up.
dropOff_datetime	The date and time of the trip dropoff.
PULocationID	TLC Taxi Zone in which the trip began.
DOlocationID	TLC Taxi Zone in which the trip ended.
SR_Flag	Indicates if the trip was a part of a shared ride chain offered by a High Volume FHV company (e.g. Uber Pool, Lyft Line). For shared trips, the value is **1**. For non-shared rides, this field is **null**. **NOTE:** For most High Volume FHV companies, only shared rides that were requested AND matched to another shared-ride request over the course of the journey are flagged. However, Lyft (base license numbers **B02510** + **B02844**) also flags rides for which a shared ride was requested but another passenger was not successfully matched to share the trip—therefore, trips records with SR_Flag=1 from those two bases could indicate EITHER a first trip in a shared trip chain OR a trip for which a shared ride was requested but never matched. Users should anticipate an overcount of successfully shared trips completed by Lyft.
Affiliated_base_number	Base number of the base with which the vehicle is affiliated. This must be provided even if the affiliated base is the same as the dispatching base.

راهنما. زمان‌های سوارشدن و پیاده‌شدن و شناسه‌های ناحیهٔ هرکدام در این فرهنگ داده تعریف شده‌اند. این فیلدها زمان و مکان آغاز و پایان سفر را مشخص می‌کنند.
منبع تصویر فرهنگ دادهٔ سفرهای FHV، NYC TLC

3 ممیزی ساختار داده

هر ردیف یک سفر ثبت‌شدهٔ HVFHV است. نمونهٔ تحلیل 240,000 ردیف دارد. در فایل‌های نمونه، تعداد ستون‌های TLC برای 2024 برابر 24 و برای 2025 برابر 25 است. به هر فایل، 3 ستون برای نمونه‌گیری اضافه شده است. شمار ستون‌ها از سرستون فایل‌ها به دست آمد.

منبع تعریف ستون‌ها، فرهنگ دادهٔ رسمی HVFHV

3.1 زمان‌های سفر

نام ستون	نوع، تعریف و کاربرد
request_datetime	تاریخ و زمان درخواست سوارشدن. مبدأ محاسبهٔ انتظار ثبت‌شده است و ساعت و روز هفتهٔ درخواست از آن استخراج می‌شوند. فرهنگ داده رویداد دقیق فنی در اپلیکیشن یا زمان قبول سفر توسط راننده را تعریف نمی‌کند. دامنهٔ این تحلیل درخواست‌هایی است که به سفر ثبت‌شده انجامیده‌اند.
on_scene_datetime	تاریخ و زمان رسیدن راننده به محل سوارشدن. فرهنگ داده این زمان را برای خودروهای دسترس‌پذیر تعریف می‌کند. اگر مقدار معتبر و ترتیب زمانی درست باشد، می‌توان انتظار را به دو فاصلهٔ درخواست تا رسیدن خودرو و رسیدن خودرو تا سوارشدن تفکیک کرد. تعمیم این تفکیک به همهٔ سفرها به بررسی پوشش ستون نیاز دارد.
pickup_datetime	تاریخ و زمان سوارشدن مسافر و آغاز سفر. اختلاف آن با زمان درخواست، متغیر هدف انتظار را می‌سازد. برای بررسی حجم سفر، روز و ساعت سوارشدن از همین ستون استخراج می‌شوند. در مدلِ لحظهٔ درخواست، این زمان برای ساخت برچسب استفاده می‌شود.
dropoff_datetime	تاریخ و زمان پیاده‌شدن مسافر و پایان سفر. اختلاف آن با زمان سوارشدن یک سنجهٔ جداگانه برای مقایسه با مدت ثبت‌شدهٔ trip_time است. ترتیب زمانی و تغییر ساعت محلی در تفسیر اختلاف اهمیت دارند.

3.2 ناحیه‌های سفر

نام ستون	نوع، تعریف و کاربرد
PULocationID	کد دسته‌ای ناحیه‌ای که سفر در آن آغاز شد. با کلید LocationID در جدول ناحیه‌ها به نام ناحیه و گروه Borough وصل می‌شود. مبنای مقایسهٔ انتظار و حجم سفر میان مبدأهاست. برای تحلیل درآمدی به پیوند جداگانه با دادهٔ درآمد ناحیه نیاز است.
DOLocationID	کد دسته‌ای ناحیه‌ای که سفر در آن پایان یافت. از همان جدول ناحیه‌ها به نام و گروه جغرافیایی تبدیل می‌شود و همراه کد مبدأ برای ساخت ماتریس مبدأ و مقصد به کار می‌رود.

این کدها مکان را در مقیاس ناحیهٔ تاکسی بیان می‌کنند. استفاده از کد مبدأ یا مقصد در مدلِ لحظهٔ درخواست به دسترسی به ناحیهٔ متناظر در همان لحظه مشروط است. راهنمای ناحیه‌های تاکسی، TLC

3.3 شناسه‌های سرویس و مرکز

نام ستون	نوع، تعریف و کاربرد
hvfhs_license_num	شناسهٔ مجوز سرویس پرحجم در TLC. کدهای HV0003 و HV0005 در این نمونه به‌ترتیب به Uber و Lyft مربوط‌اند. این ستون برای تفکیک سرویس‌ها و مقایسهٔ الگوی انتظار به کار می‌رود.
dispatching_base_num	شمارهٔ مجوز مرکزی که اعزام خودرو برای این سفر را انجام داده است. یک سرویس می‌تواند از چند مرکز استفاده کند، بنابراین سطح این شناسه از شناسهٔ سرویس جزئی‌تر است.
originating_base_num	شمارهٔ مجوز مرکزی که درخواست اولیهٔ سفر را دریافت کرده است. این ستون مرحلهٔ دریافت درخواست را مشخص می‌کند و ستون مرکز اعزام، مسئول اعزام را. مقایسهٔ این دو به رکوردهایی با هر دو کد معتبر محدود است.

3.4 مدت، مسافت و کرایهٔ پایه

نام ستون	نوع، تعریف و کاربرد
trip_time	مدت ثبت‌شدهٔ سفر مسافر، به ثانیه. در تحلیل توصیفی به دقیقه تبدیل می‌شود و با فاصلهٔ زمانی سوارشدن تا پیاده‌شدن مقایسه می‌شود. در برآورد سرعت تقریبی، مسافت بر مدت مثبت سفر تقسیم می‌شود.
trip_miles	مسافت ثبت‌شدهٔ سفر مسافر، به مایل. برای مقایسهٔ توزیع طول سفر، مدت، کرایه و سرعت تقریبی به کار می‌رود. فرهنگ داده روش اندازه‌گیری را مشخص نمی‌کند. کاربرد آن در این فاز پس‌نگر است.
base_passenger_fare	کرایهٔ پایهٔ گزارش‌شدهٔ مسافر، به دلار آمریکا، پیش از عوارض مسیر، انعام، مالیات و هزینه‌های اضافه. برای مقایسهٔ کرایه با مدت و مسافت به کار می‌رود. زمان تعیین یا نمایش مبلغ به مسافر از خود این ستون معلوم نمی‌شود.

3.5 نشانگرهای سفر

نشانگرهای زیر در فرهنگ داده با Y و N تعریف شده‌اند.

نام ستون	نوع، تعریف و کاربرد
shared_request_flag	مسافر با گزینهٔ سفر اشتراکی موافقت کرده است. مقدار مثبت می‌تواند به سفری منجر شود که مسافر دیگری برای آن پیدا نشده است.
shared_match_flag	مسافر در بخشی از سفر با فردی که جداگانه رزرو کرده، در یک خودرو بوده است. سهم هم‌سفری تحقق‌یافته در این گزارش با همین ستون محاسبه می‌شود.
access_a_ride_flag	سفر به نمایندگی از سازمان حمل‌ونقل شهری MTA و در چارچوب خدمت Access-A-Ride انجام شده است.
wav_request_flag	مسافر خودروی قابل‌دسترسی با ویلچر (WAV) درخواست کرده است. این نشانگر به نیاز اعلام‌شده هنگام درخواست مربوط است.
wav_match_flag	سفر با خودروی قابل‌دسترسی با ویلچر انجام شده است. این نشانگر نوع خودروی استفاده‌شده را ثبت می‌کند.

3.6 عوارض، مالیات و مبالغ تکمیلی

مقادیر پولی زیر برای هر سفر به دلار آمریکا گزارش می‌شوند.

نام ستون	نوع، تعریف و کاربرد
tolls	جمع عوارض پرداخت‌شده برای عبور از مسیر، مانند عوارض پل یا تونل. به مسیر طی‌شده وابسته است.
bcf	مبلغ دریافت‌شده برای Black Car Fund در آن سفر. این جزء به‌صورت جداگانه در داده ثبت شده است.
sales_tax	مبلغ مالیات فروش ایالت نیویورک که برای سفر دریافت شده و جدا از کرایهٔ پایه گزارش می‌شود.
congestion_surcharge	مبلغ عوارض ازدحام ایالت نیویورک برای آن سفر. این عوارض در ستون جداگانه‌ای از هزینهٔ محدودهٔ کاهش ازدحام MTA گزارش می‌شود.
airport_fee	هزینهٔ فرودگاهی ثبت‌شده برای سوارشدن یا پیاده‌شدن در فرودگاه‌های LaGuardia، Newark و JFK طبق فرهنگ داده.
tips	مجموع انعام دریافت‌شده از مسافر که جدا از کرایهٔ پایه و ستون پرداخت به راننده گزارش می‌شود.
driver_pay	مبلغ پرداختی گزارش‌شده به راننده، بدون عوارض مسیر و انعام و پس از کسر کمیسیون، هزینه‌های اضافه و مالیات طبق تعریف TLC.
cbd_congestion_fee	هزینهٔ هر سفر برای محدودهٔ کاهش ازدحام MTA. این ستون در نمونهٔ 2025 وجود دارد و در نمونهٔ 2024 غایب است. هنگام کنار هم گذاشتن دو سال، نبود ستون در فایل قدیمی باید به‌عنوان تفاوت ساختار فایل ثبت شود.

3.7 ستون‌های نمونه‌گیری

این ستون‌ها در زمان ساخت نمونه به فایل اضافه شدند.

نام ستون	نوع، تعریف و کاربرد
_sample_source_month	ماه فایل مبدأ. واحد نمونه‌گیری و مرجع کنترل تطابق با ماه سوارشدن است.
_sample_source_row	شمارهٔ ردیف در فایل مبدأ. ترکیب آن با ماه فایل، کلید ردیف برای بررسی تکرار در نمونه است.
_sample_weight	وزن عددی هر ردیف، برابر تعداد سفرهای فایل ماه تقسیم بر تعداد ردیف‌های نمونهٔ همان ماه. مجموع وزن‌ها برآورد تعداد سفرهاست. سهم هر گروه با تقسیم وزن آن بر وزن ردیف‌های معتبر و صدک با رسیدن سهم وزن انباشته به آستانهٔ موردنظر محاسبه می‌شود.

4 ممیزی کیفیت

4.1 متغیرهای اصلی

ممیزی بر 240,000 سفر نمونه در سال‌های 2024 و 2025 انجام شد. اولویت با متغیرهای لازم برای محاسبهٔ انتظار، مقایسهٔ نواحی و تفکیک سرویس‌ها بود.

جدول 1. کنترل کیفیت متغیرهای اصلی و تصمیم استفاده از آن‌ها

بررسی	یافته	نتیجه برای تحلیل
زمان‌های درخواست و سوارشدن	0 ردیف با زمان خالی یا خوانده‌نشدنی و 0 مغایرت ماه سوارشدن با فایل مبدأ	محاسبهٔ انتظار به خوانا بودن هر دو زمان نیاز دارد.
فاصلهٔ درخواست تا سوارشدن	2,584 انتظار منفی، 1.08%، و 4 انتظار صفر	ردیف‌های منفی فقط از تحلیل انتظار کنار گذاشته شدند. انتظار صفر حفظ شد.
شناسه‌های مبدأ و مقصد	0 ردیف با شناسهٔ خالی یا فاقد تطابق با جدول کدها	7 مبدأ خارج از شهر برای مقایسهٔ درآمد نواحی نیویورک جدا می‌شوند.
شناسهٔ سرویس	0 ردیف با شناسهٔ خالی یا خارج از HV0003 و HV0005	سفرها به تفکیک سرویس گزارش می‌شوند.
وزن و شناسهٔ ردیف نمونه‌گیری	0 وزن خالی، نامتناهی یا نامثبت و 0 تکرار کلید ماه و ردیف در نمونه	هر ماه 10,000 ردیف نمونه دارد و وزن‌ها در تحلیل اکتشافی به کار رفتند.

یادداشت. شمارها و درصدها بر مبنای ردیف‌های نمونه‌اند. کلید ردیف از ماه فایل مبدأ و شمارهٔ ردیف در همان فایل ساخته می‌شود.

4.2 زمان انتظار

در 2024، 1,191 ردیف و در 2025، 1,393 ردیف انتظار منفی داشتند. سهم این ردیف‌ها از کل ردیف‌های هر سرویس برای HV0003 برابر 0.82% و برای HV0005 برابر 1.78% بود. از میان انتظارهای نامنفی، 12,420 مقدار با معیار 1.5 برابر دامنهٔ میان‌چارکی به‌عنوان پرت بالقوه علامت‌گذاری شدند و در آمار باقی ماندند.

4.3 متغیرهای تحلیل اکتشافی

در 0 ردیف، دست‌کم یکی از متغیرهای زمان پیاده‌شدن، مدت و مسافت سفر، کرایهٔ پایه یا نشانگر هم‌سفری فاقد مقدار معتبر بود. مقادیر پذیرفته‌شده برای نشانگر هم‌سفری Y و N هستند. آخرین تاریخ پیاده‌شدن در نمونه 2026-01-01 است. موارد ناسازگار مدت، مسافت و کرایه در جدول 6 آمده‌اند.

5 تحلیل اکتشافی تک‌متغیره

5.1 آمار توصیفی

سال هر سفر از زمان سوارشدن استخراج شد. شمار ردیف‌های نمونه برای 2024 و 2025 به‌ترتیب 120,000 و 120,000 است. جمع وزن‌ها در همین ترتیب 239,470,448 و 243,589,684 سفر است.

جدول 2. مرکز، پراکندگی و صدک‌های وزن‌دار متغیرهای عددی به تفکیک سال

متغیر و واحد	سال	ردیف معتبر	میانگین	انحراف معیار	میانه	چارک‌ها	صدک 95
زمان انتظار، دقیقه	2024	118,809	4.66	2.99	3.98	2.78-5.70	10.07
	2025	118,607	4.81	3.24	4.05	2.80-5.87	10.75
مدت سفر، دقیقه	2024	120,000	20.14	14.46	16.35	10.10-25.90	48.10
	2025	120,000	19.80	14.20	16.10	9.97-25.52	47.05
مسافت، مایل	2024	120,000	5.10	5.95	3.02	1.58-6.39	16.65
	2025	120,000	5.00	5.77	2.98	1.54-6.28	16.31
کرایهٔ پایه، دلار	2024	120,000	26.23	23.16	19.62	12.51-31.33	67.25
	2025	120,000	26.88	24.26	19.58	12.49-32.21	70.93

یادداشت. «ردیف معتبر» تعداد خام سفرهای واردشده به محاسبهٔ هر متغیر است. آمار با وزن نمونه‌گیری محاسبه شده‌اند. «چارک‌ها» بازهٔ صدک 25 تا 75 است. در صدک 95، وزن انباشته به 95% می‌رسد.

هر چهار توزیع در هر دو سال راست‌چوله‌اند. میانهٔ وزن‌دار انتظار در 2024 و 2025 به‌ترتیب 3.98 و 4.05 دقیقه بود. سهم وزن‌دار انتظار بیش از 10 دقیقه به‌ترتیب 5.11% و 6.23% بود.

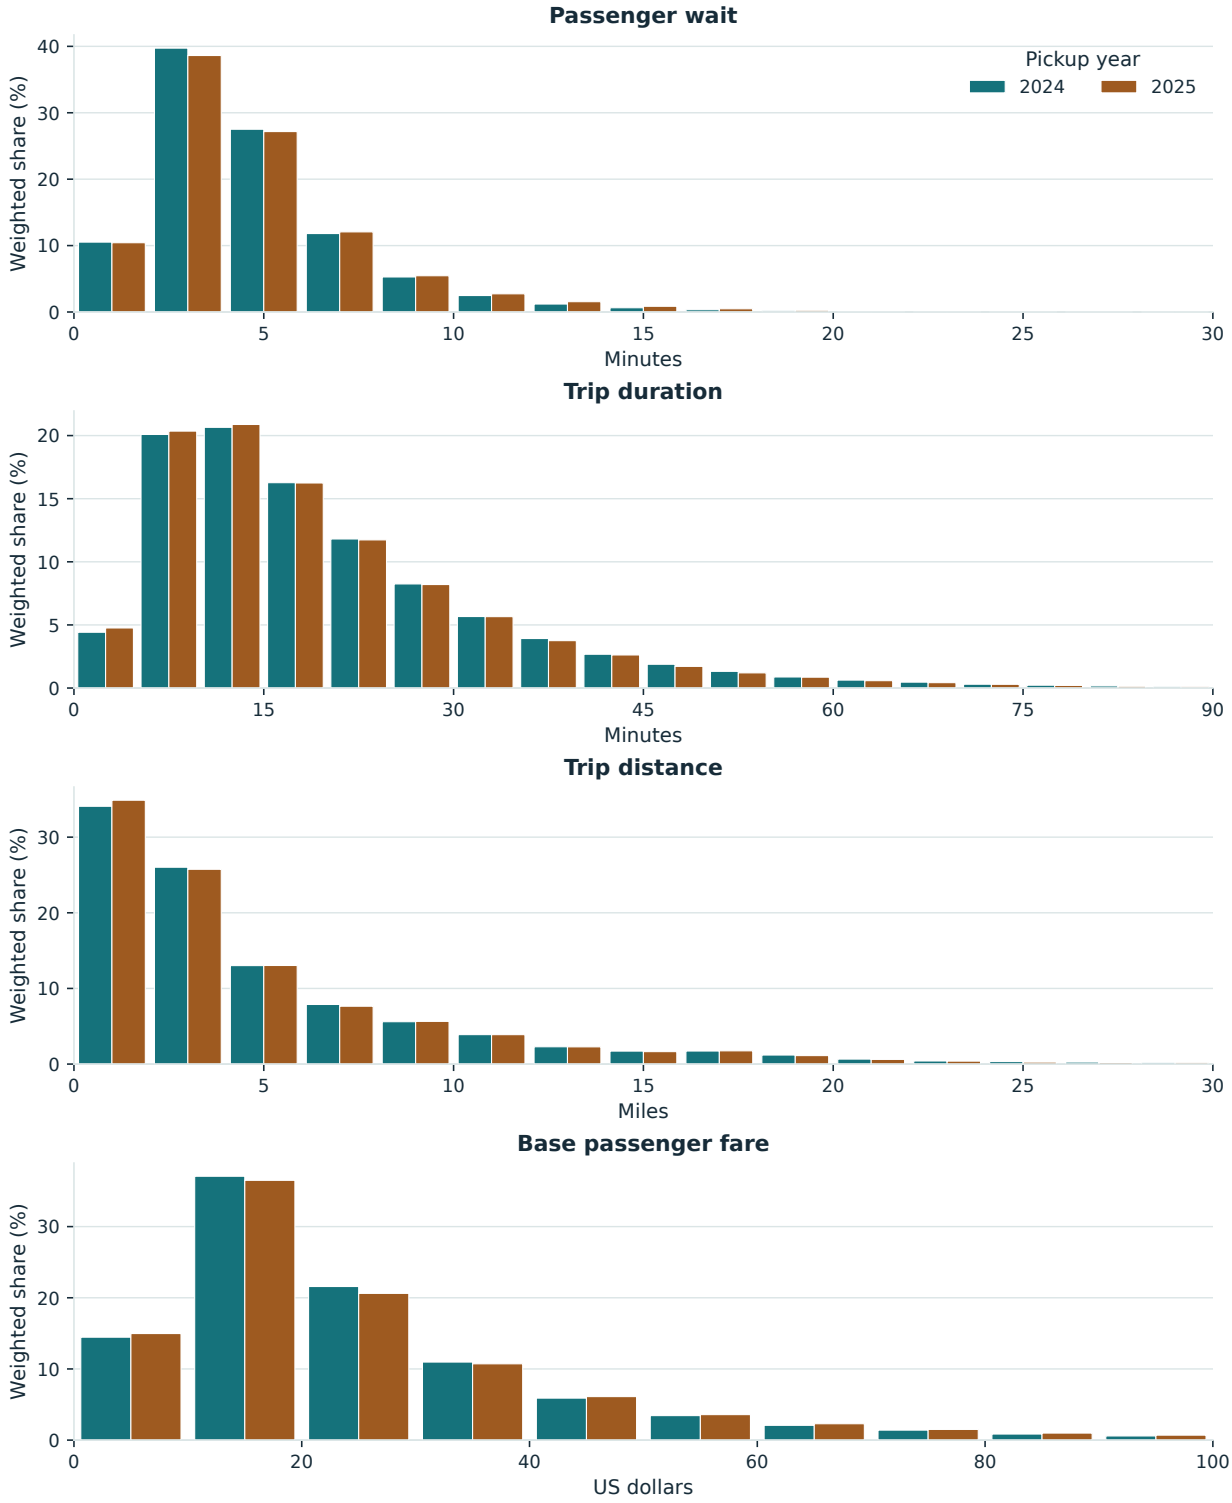
جدول 3. تعداد برآوردی سفر و سهم سرویس‌ها و هم‌سفری به تفکیک سال

سال	HV0003	HV0005	هم‌سفری ثبت‌شده
2024	179,119,970 (74.80%)	60,350,478 (25.20%)	3,767,548 (1.57%)
2025	176,358,982 (72.40%)	67,230,702 (27.60%)	3,975,416 (1.63%)

یادداشت. هر خانه تعداد برآوردی سفر را نشان می‌دهد. درصد داخل پرانتز سهم آن گروه از کل وزن سفرهای همان سال است. «هم‌سفری» یعنی مسافر در بخشی از مسیر با مسافری که جداگانه رزرو کرده بود، هم‌سفر شده است. این ستون با گروه‌های سرویس هم‌پوشانی دارد.

5.2 توزیع‌ها در نمونهٔ مرجع با 10,000 ردیف در ماه

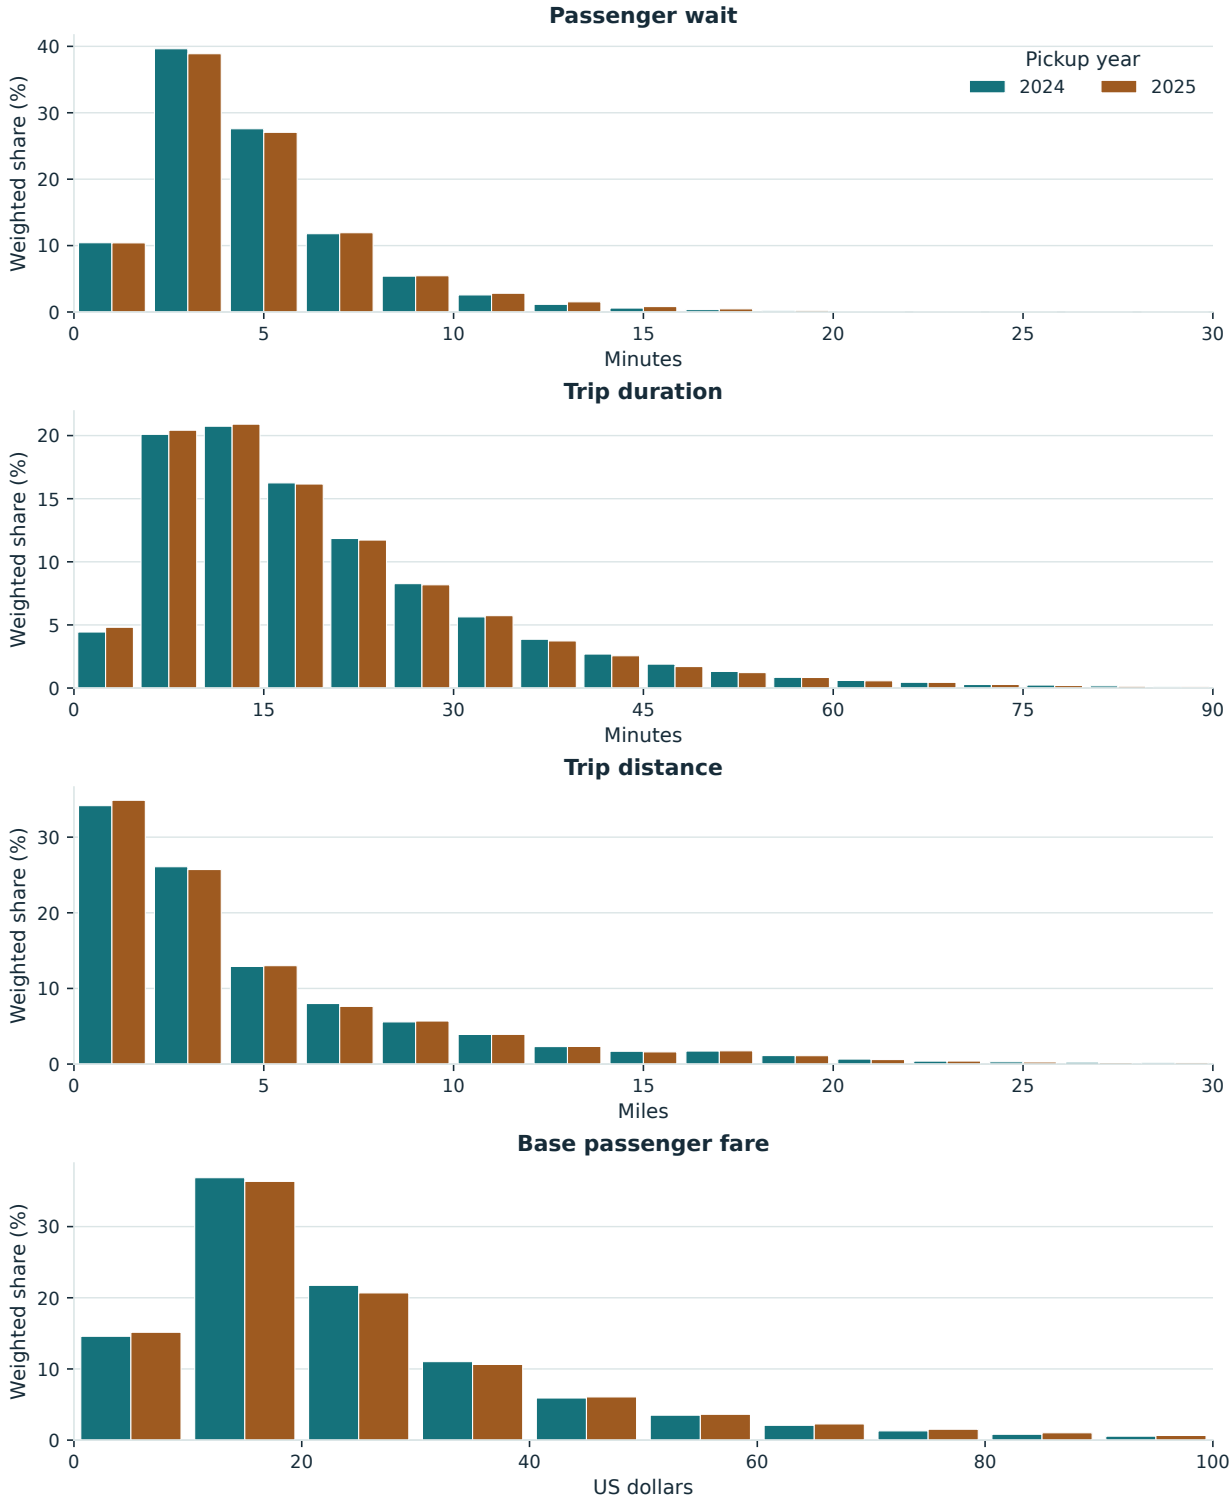
شکل 4. توزیع وزن‌دار انتظار، مدت، مسافت و کرایهٔ پایه در نمونهٔ مرجع



راهنما. آبی‌سبز برای 2024 و اخرایی برای 2025 است. هر پنل واحد متغیر را روی محور افقی نشان می‌دهد. ارتفاع میله، درصد وزن سفرهای آن بازه از کل وزن مقادیر معتبر همان سال است. مقادیر خارج از محدودهٔ نمایش هم در مخرج درصدها لحاظ شده‌اند.
سهم وزن بیرون بازه در 2024 و 2025 به‌ترتیب برای انتظار 0.05% و 0.05%، مدت سفر 0.28% و 0.28%، مسافت 0.74% و 0.70% و کرایهٔ پایه 1.66% و 2.00% بود.

5.3 توزیع‌ها در نمونهٔ کوچک‌تر با 5,000 ردیف در ماه

شکل 5. توزیع وزن‌دار چهار متغیر با 5,000 سفر نمونه در ماه



راهنما. این شکل یک نمونه‌گیری با بذر 42 را نشان می‌دهد. وزن ردیف‌های انتخاب‌شده در 2 ضرب شده است. رنگ سال‌ها، بازه‌های هیستوگرام و مقیاس محورها با شکل 4 یکسان‌اند. ارتفاع هر میله سهم وزن آن بازه از وزن مقادیر معتبر همان سال است.

5.4 ارزیابی کفایت اندازهٔ نمونه

از هر یک از 24 ماه، 5,000 ردیف از 10,000 ردیف مرجع به‌صورت تصادفی و بدون جایگذاری انتخاب شد. این کار برای 20 بذر از 42 تا 61 تکرار شد. احتمال انتخاب در این مرحله 50% بود و وزن هر ردیف منتخب در 2 ضرب شد. جمع وزن ردیف‌های هر ماه همچنان تعداد سفرهای فایل مبدأ همان ماه را نشان می‌دهد. هر نمونهٔ کوچک‌تر 120,000 ردیف، معادل 60,000 ردیف برای هر سال، دارد.

معیارهای عملی مقایسه، اختلاف حداکثر 1 واحد درصد در ارتفاع میله‌های متناظر و تغییر نسبی حداکثر 5% در صدک وزن‌دار 95 بودند. جدول 4 بیشترین اختلاف مشاهده‌شده در 20 نمونه‌گیری را برای هر سال و متغیر نشان می‌دهد. درصد هر میله بر اساس مجموع وزن مقادیر معتبر همان سال محاسبه شد.

جدول 4. بیشترین اختلاف نمونهٔ کوچک‌تر با مرجع در 20 تکرار

متغیر	اختلاف ارتفاع میله، واحد درصد		تغییر نسبی صدک 95، درصد	
	2024	2025	2024	2025
زمان انتظار	0.318	0.280	0.662	0.775
مدت سفر	0.308	0.315	0.658	0.956
مسافت سفر	0.323	0.314	1.321	1.042
کرایهٔ پایه	0.260	0.435	1.517	0.705

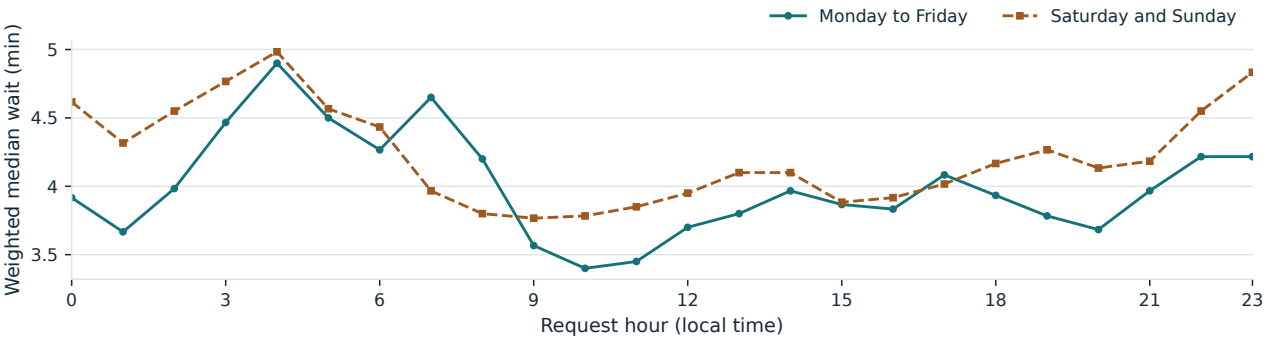
یادداشت. اختلاف میله‌ها، قدرمطلق تفاضل دو سهم وزن‌دار بر حسب واحد درصد است. تغییر صدک 95، قدرمطلق اختلاف دو صدک تقسیم بر صدک مرجع و ضرب در 100 است. هر خانه بزرگ‌ترین مقدار مشاهده‌شده در 20 تکرار را نشان می‌دهد.

نتیجه. بیشترین اختلاف ارتفاع میله‌ها 0.435 واحد درصد و بیشترین تغییر نسبی صدک 95 برابر 1.517% بود. با معیارهای بالا، نمونهٔ 5,000 ردیفی برای بازتولید شکل کلی توزیع‌ها و صدک 95 متغیرها در مقایسه با نمونهٔ مرجع 10,000 ردیفی کافی است.

6 تحلیل اکتشافی چندمتغیره

6.1 روابط زمان انتظار

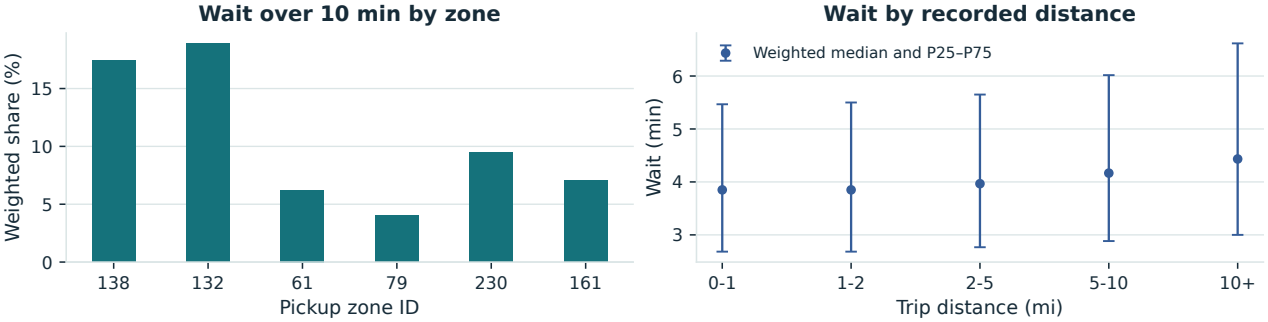
شکل 6. میانهٔ وزن‌دار زمان انتظار به تفکیک ساعت درخواست و نوع روز



راهنما. محور افقی ساعت محلی درخواست و محور عمودی میانهٔ وزن‌دار انتظار به دقیقه است. خط پیوستهٔ آبی‌سبز برای دوشنبه تا جمعه و خط‌چین اخرایی برای شنبه و یکشنبه است. هر دو خط از داده‌های دو سال محاسبه شده‌اند.

میانهٔ وزن‌دار انتظار در ساعت 7 در دوشنبه تا جمعه 4.65 دقیقه و در شنبه و یکشنبه 3.97 دقیقه بود. در ساعت 23، میانه به‌ترتیب 4.22 و 4.83 بود. این برآورد از 237,416 ردیف معتبر نمونه استفاده می‌کند.

شکل 7. سهم انتظار طولانی در ناحیه‌های پرتردد و توزیع انتظار بر حسب مسافت سفر



راهنما. پنل چپ 6 ناحیه با بیشترین برآورد تعداد سفر را نشان می‌دهد. هر میله سهم وزن سفرهای با انتظار بیش از 10 دقیقه از وزن سفرهای با انتظار معتبر همان ناحیه است. در پنل راست، نقطه میانهٔ وزن‌دار انتظار به دقیقه و خط عمودی بازهٔ صدک‌های 25 تا 75 است. حد بالای هر بازهٔ مسافت در گروه بعدی قرار می‌گیرد.

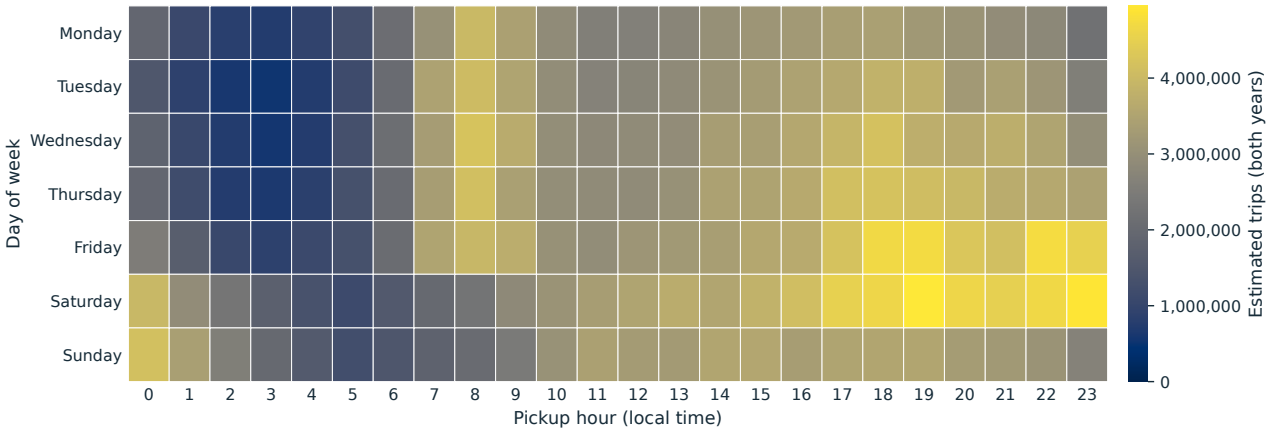
ناحیهٔ سوارشدن. سهم وزن‌دار انتظار بیش از 10 دقیقه از 4.00% در ناحیهٔ 79 تا 18.86% در ناحیهٔ 132 متغیر بود.

مسافت سفر. میانهٔ وزن‌دار انتظار برای سفرهای زیر 1 مایل 3.85 دقیقه و برای سفرهای دست‌کم 10 مایل 4.43 دقیقه بود.

این روابط توصیفی‌اند. اختلاف نواحی به‌تنهایی رابطهٔ درآمد ناحیه با زمان انتظار را مشخص نمی‌کند. مقایسهٔ درآمدی به پیوند رکوردهای سفر با دادهٔ درآمد ناحیهٔ مبدأ نیاز دارد.

6.2 ممیزی زمان سفر

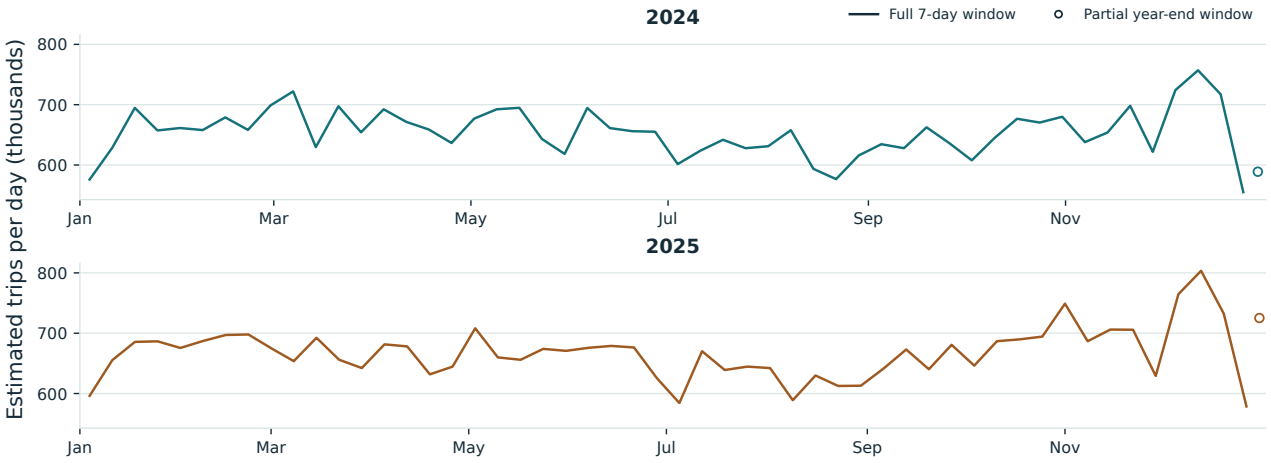
شکل 8. برآورد مجموع سفرهای 2024 و 2025 بر حسب روز هفته و ساعت سوارشدن



راهنما. سطرها روز هفته و ستون‌ها ساعت محلی سوارشدن‌اند. ستون 19، بازهٔ 19:00 تا پیش از 20:00 است. هر خانه مجموع وزن سفرهای همان روز و ساعت در دو سال را نشان می‌دهد. رنگ روشن‌تر یعنی سفر بیشتر.

نقشه از 240,000 ردیف نمونه ساخته شده و جمع وزن خانه‌های آن 483,060,132 سفر است. بیشترین برآورد برای شنبه در ساعت 19 با 4,950,595 سفر و کمترین برای سه‌شنبه در ساعت 3 با 528,884 سفر است.

شکل 9. میانگین روزانهٔ سفر در بازه‌های 7 روزه به تفکیک سال



راهنما. بازه‌ها از اول ژانویه آغاز می‌شوند. در میانهٔ هر بازه، مجموع وزن سفرها تقسیم بر تعداد روزها رسم شده است. محور عمودی بر حسب هزار سفر در روز است. خط‌ها بازه‌های کامل و دایرهٔ توخالی بازهٔ پایانیِ ناقص هر سال را نشان می‌دهند که در 2024 2 روز و در 2025 1 روز است.

نمونه 731 روز با سفر ثبت‌شده را پوشش می‌دهد. 0 ردیف زمان درخواست، سوارشدن یا پیاده‌شدنِ خوانده‌نشدنی داشتند.

جدول 5. بازه‌های 7 روزه با بیشترین و کمترین برآورد سفر در روز

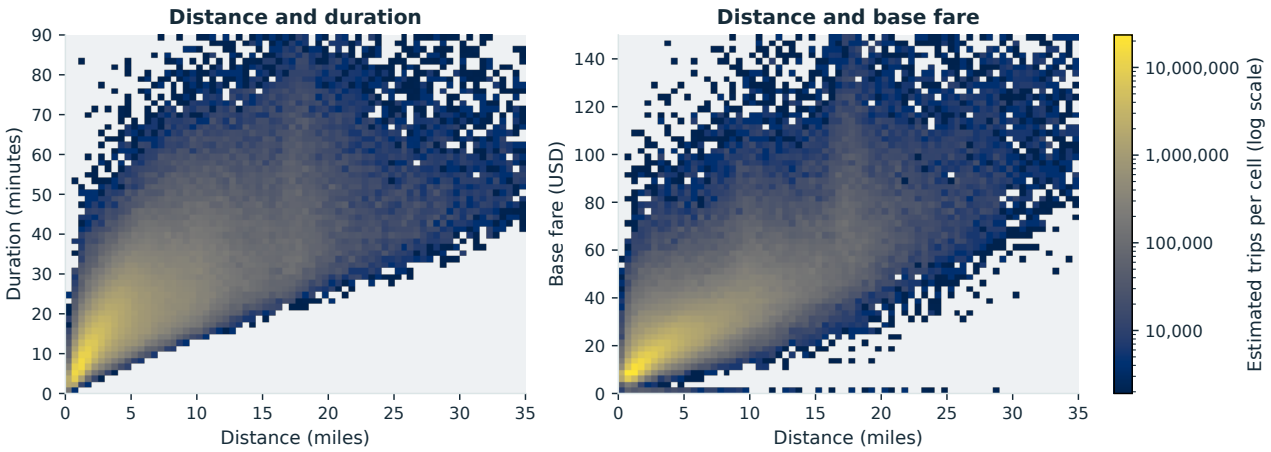
سال	بیشینهٔ سفر در روز	بازهٔ پرحجم	کمینهٔ سفر در روز	بازهٔ کم‌حجم
2024	756,974	9 تا 15 دسامبر	555,014	23 تا 29 دسامبر
2025	803,484	10 تا 16 دسامبر	578,609	24 تا 30 دسامبر

یادداشت. برای هر بازهٔ کامل، مجموع وزن سفرها بر 7 تقسیم شده است. تاریخ‌ها ابتدا و انتهای بازهٔ کمینه و بیشینه را نشان می‌دهند.

6.3 سازگاری متغیرهای سفر

سرعت تقریبی با تقسیم مسافت بر مدت ثبت‌شدهٔ سفر و تبدیل ثانیه به ساعت محاسبه شد. میانهٔ وزن‌دار سرعت 11.48 و صدک 95 آن 28.55 مایل‌برساعت بود. شکل 10 توزیع مشترک مسافت با مدت و کرایهٔ پایه را نشان می‌دهد.

شکل 10. توزیع مشترک مسافت سفر با مدت ثبت‌شده و کرایهٔ پایه



راهنما. محور افقی مسافت بر حسب مایل است. محور عمودی در پنل چپ مدت سفر به دقیقه و در پنل راست کرایهٔ پایه به دلار است. هر خانه مجموع وزن سفرهای آن بازه را نشان می‌دهد و هر دو پنل از مقیاس رنگ لگاریتمی یکسان استفاده می‌کنند.

محدودهٔ نمایش تا 35 مایل، 90 دقیقه و 150 دلار است. پنل مدت و پنل کرایه به‌ترتیب 99.38% و 99.33% از وزن کل سفرها را پوشش می‌دهند.

برای سفرهای کمتر از 1 مایل و سفرهای دست‌کم 10 مایل، میانهٔ وزن‌دار مدت به‌ترتیب 5.63 و 39.35 دقیقه، کرایه 8.90 و 56.18 دلار و سرعت 7.94 و 23.63 مایل‌برساعت بود.

جدول 6. ردیف‌های علامت‌گذاری‌شده در کنترل مدت، مسافت و کرایهٔ پایه

نشانه	ردیف نمونه	سهم وزن‌دار
اختلاف بیش از 1 ثانیه بین مدت ثبت‌شده و مدت محاسبه‌شده	34	0.0145%
کرایهٔ پایهٔ منفی	11	0.0046%
کرایهٔ پایهٔ صفر	216	0.0894%
مسافت صفر با مدت مثبت	27	0.0112%

یادداشت. «ردیف نمونه» شمار خام موارد و «سهم وزن‌دار» وزن همان موارد تقسیم بر وزن کل سفرهاست. مدت محاسبه‌شده از اختلاف زمان پیاده‌شدن و سوارشدن به دست می‌آید. یک ردیف می‌تواند در چند دسته شمرده شود.

در 24 مورد از 34 ردیف، اختلاف دو مدت حدود یک ساعت بود و تاریخ سفر با تغییر ساعت رسمی نیویورک هم‌زمان بود. قواعد تغییر ساعت، NIST

6.4 الگوهای مکانی سفر

6.4.1 ساخت نمای مکانی اولیه

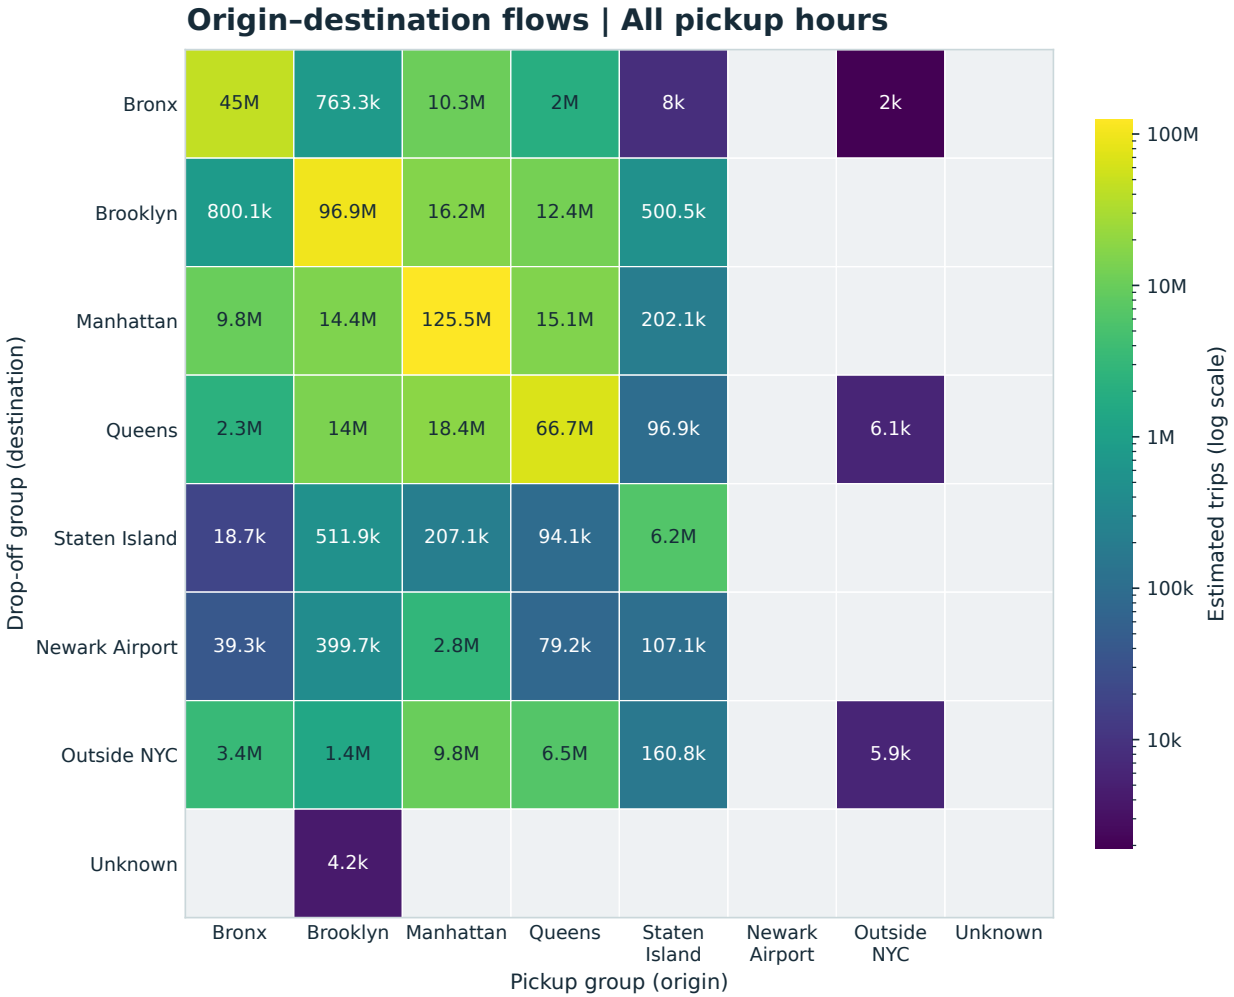
شناسهٔ محل سوارشدن و پیاده‌شدن هر سفر با ستون Borough از جدول ناحیه‌های تاکسی به گروه جغرافیایی تبدیل شد. 5 بخش شهر نیویورک، فرودگاه نیوآرک، خارج از شهر و مکان نامشخص، 8 گروه تحلیل را تشکیل می‌دهند. شناسهٔ 264 مکان نامشخص و شناسهٔ 265 خارج از شهر را نشان می‌دهد. راهنمای ناحیه‌های تاکسی و جدول کدهای TLC

هر سه نقشه هر دو سال را پوشش می‌دهند و ترتیب گروه‌ها در آن‌ها یکسان است. دو برش زمانی بر اساس ساعت محلی سوارشدن‌اند و پایان هر بازه در بازهٔ بعدی قرار می‌گیرد. مقادیر هر برش، حجم تجمعی سفرها در بازه‌های 8 و 16 ساعته‌اند. شکل 14 همین گروه‌های مبدأ را به تفکیک ساعت سوارشدن نمایش می‌دهد.

در میان سفرهایی که مبدأ و مقصدشان در 5 بخش شهر است، سفرهای درون یک بخش 74.23% از مجموع وزن را تشکیل می‌دهند. سهم مقصد «خارج از شهر» به‌جز فرودگاه نیوآرک، 4.40% از کل وزن سفرهاست.

6.4.2 نقشه‌های مبدأ و مقصد

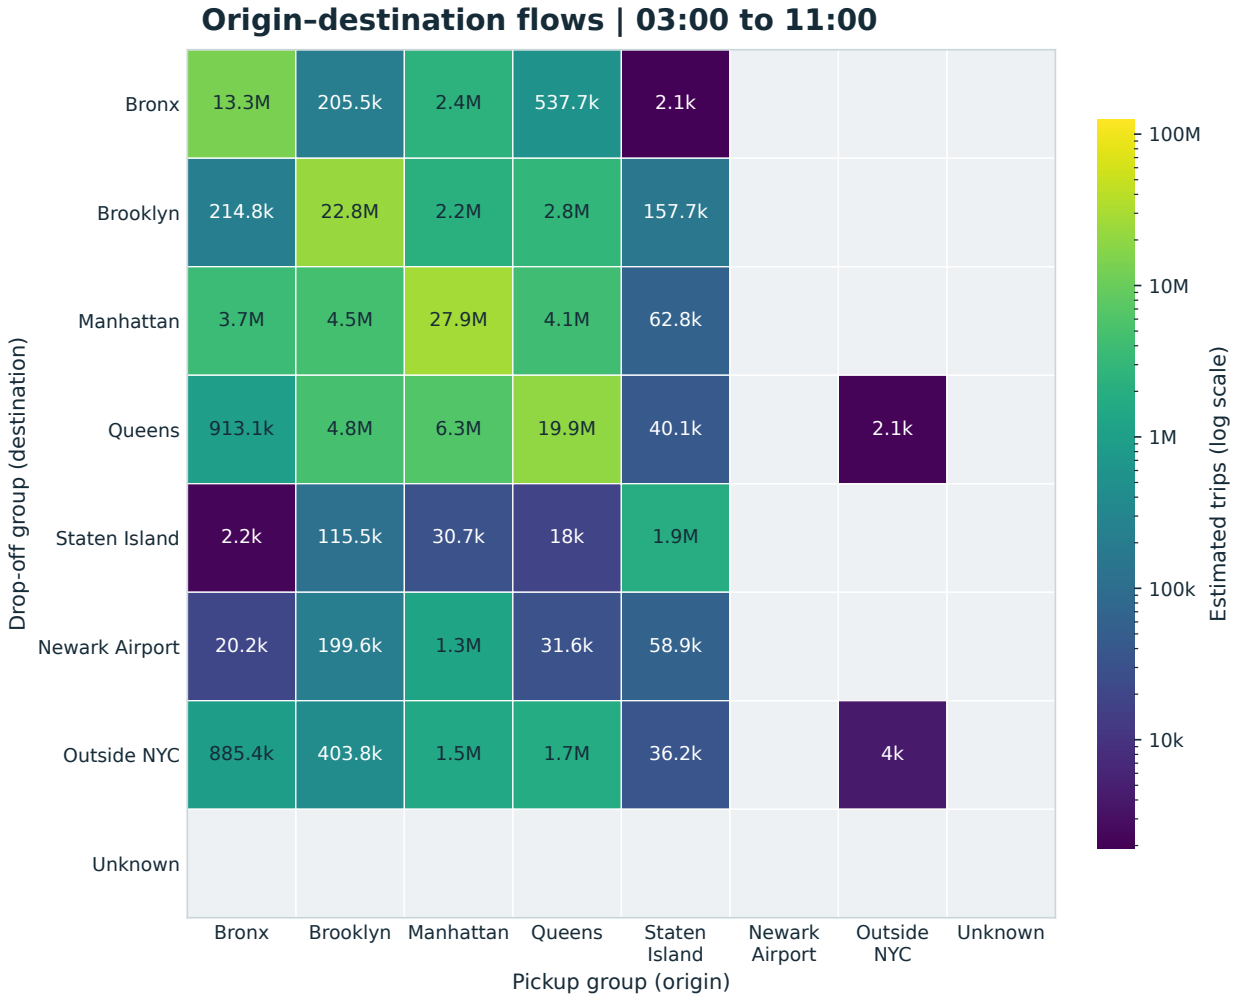
شکل 11. حجم سفر بین گروه‌های مبدأ و مقصد در کل شبانه‌روز



راهنما. ستون‌ها گروه مبدأ و سطرها گروه مقصدند. عدد هر خانه برآورد مجموع سفرهای همان جفت و بازه در دو سال است. k هزار و M میلیون سفر است. رنگ روشن‌تر حجم بیشتر را روی مقیاس لگاریتمی مشترک سه نقشه نشان می‌دهد. خانهٔ خاکستری یعنی در نمونه سفری برای آن جفت و بازه ثبت نشده است.

6.4.2 نقشه‌های مبدأ و مقصد

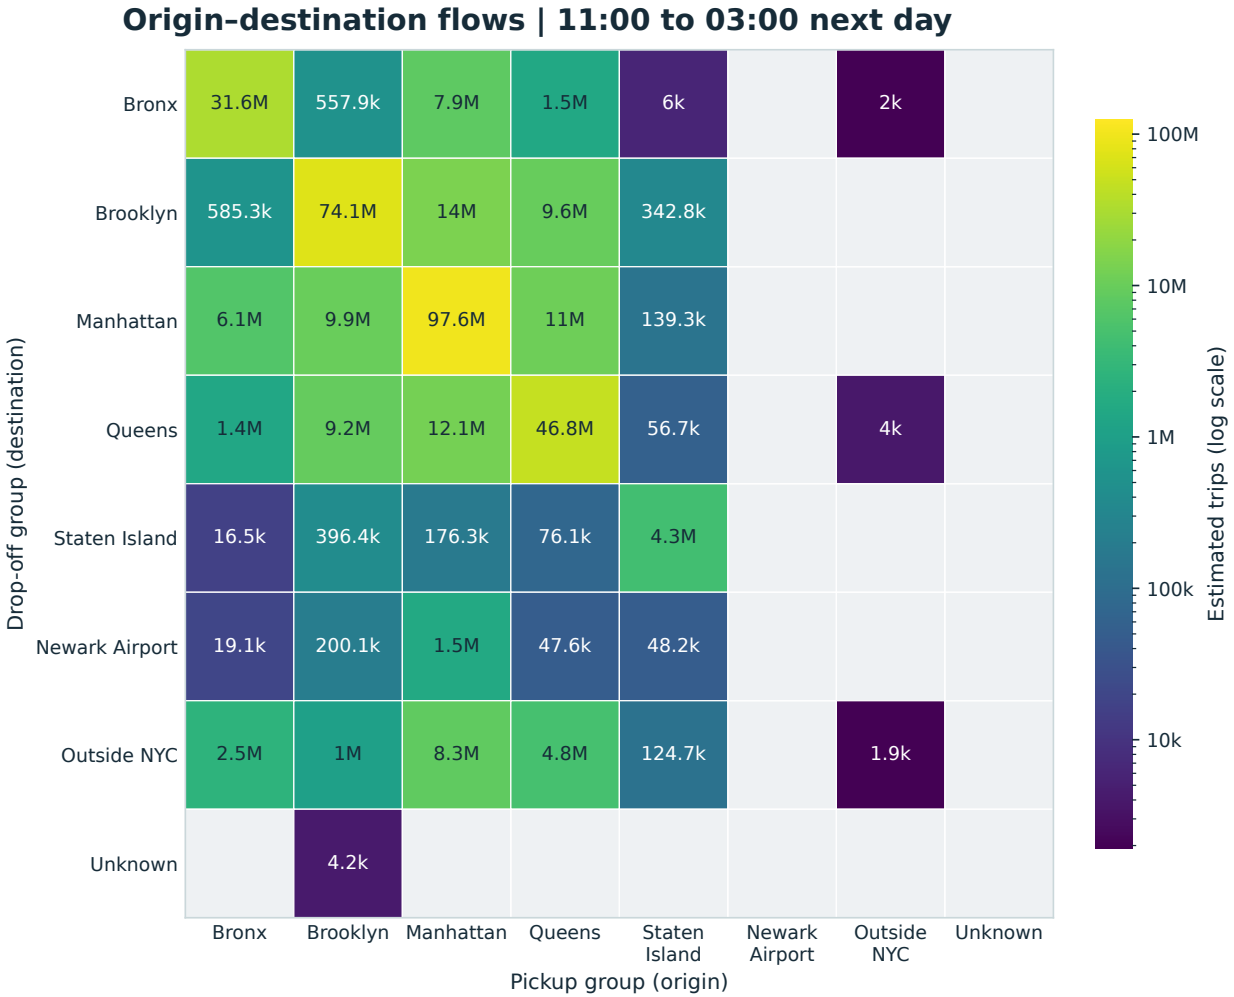
شکل 12. حجم سفر بین مبدأ و مقصد از 03:00 تا پیش از 11:00



راهنما. ستون‌ها گروه مبدأ و سطرها گروه مقصدند. عدد هر خانه برآورد مجموع سفرهای همان جفت و بازه در دو سال است. k هزار و M میلیون سفر است. رنگ روشن‌تر حجم بیشتر را روی مقیاس لگاریتمی مشترک سه نقشه نشان می‌دهد. خانهٔ خاکستری یعنی در نمونه سفری برای آن جفت و بازه ثبت نشده است.

6.4.2 نقشه‌های مبدأ و مقصد

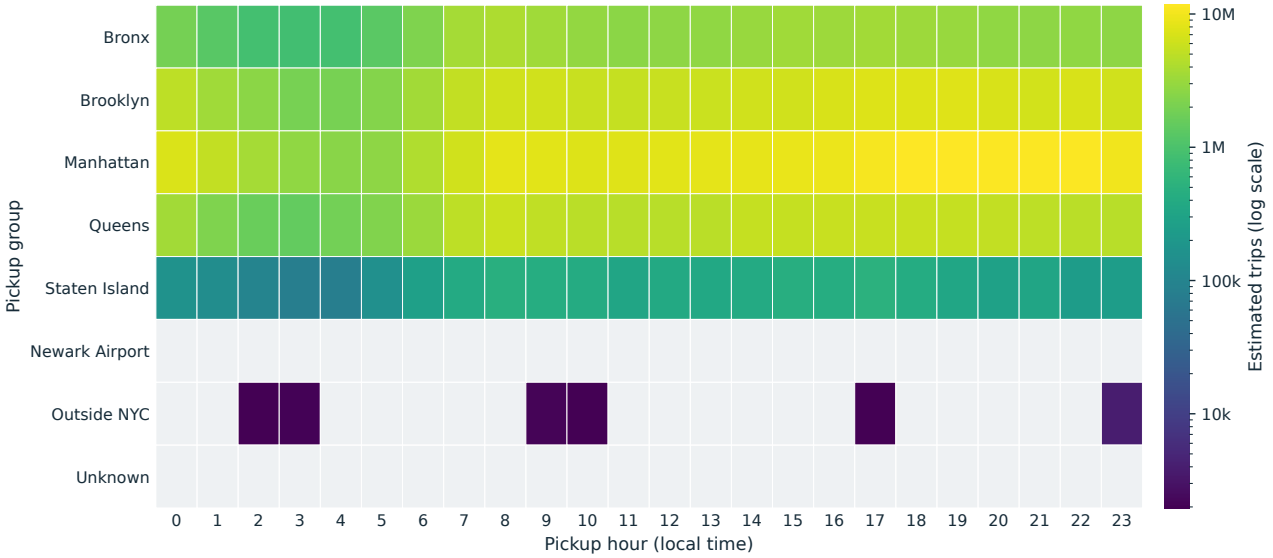
شکل 13. حجم سفر بین مبدأ و مقصد از 11:00 تا پیش از 03:00 روز بعد



راهنما. ستون‌ها گروه مبدأ و سطرها گروه مقصدند. عدد هر خانه برآورد مجموع سفرهای همان جفت و بازه در دو سال است. k هزار و M میلیون سفر است. رنگ روشن‌تر حجم بیشتر را روی مقیاس لگاریتمی مشترک سه نقشه نشان می‌دهد. خانهٔ خاکستری یعنی در نمونه سفری برای آن جفت و بازه ثبت نشده است.

6.4.3 زمان سوارشدن به تفکیک گروه مبدأ

شکل 14. برآورد مجموع سفرهای دو سال به تفکیک گروه مبدأ و ساعت سوارشدن



راهنما. هر سطر یک گروه مبدأ و هر ستون یک ساعت محلی سوارشدن است. رنگ هر خانه برآورد تعداد سفرهای آن گروه و ساعت را روی مقیاس لگاریتمی نشان می‌دهد. در نوار رنگ، k هزار و M میلیون سفر است. خانهٔ خاکستری یعنی در نمونه سفری برای آن گروه و ساعت ثبت نشده است.

7 تعریف خطر نشت اطلاعات

لحظهٔ پیش‌بینی، زمان ثبت درخواست است. نشت اطلاعات زمانی رخ می‌دهد که ورودی یا فرایند ساخت مدل از اطلاعاتی استفاده کند که در آن لحظه در دسترس نبوده است. هدف، فاصلهٔ درخواست تا سوارشدن است و همین تعریف تعیین می‌کند چه ستون‌هایی مجازند.

ورودی‌های قابل استفاده. سرویس انتخاب‌شده، ساعت درخواست و روز هفته ورودی‌های آغازین‌اند. ساعت و روز هفته از `request_datetime` استخراج می‌شوند. استفاده از `PULocationID` و `DOLocationID` به تأیید دسترسی به ناحیهٔ متناظر در همان لحظه نیاز دارد، زیرا این ستون‌ها محل واقعی آغاز و پایان سفر را ثبت می‌کنند.

ستون‌های دارای اطلاعات آینده. `pickup_datetime` مستقیماً در ساخت هدف به کار می‌رود و ساعت استخراج‌شده از آن نیز اطلاعات زمان سوارشدن را وارد مدل می‌کند. زمان رسیدن خودرو، زمان پیاده‌شدن، مدت و مسافت تحقق‌یافتهٔ سفر و نتیجهٔ هم‌سفری نیز پس از درخواست معلوم می‌شوند. بنابراین `on_scene_datetime`، `dropoff_datetime`، `trip_time`، `trip_miles` و `shared_match_flag` از ورودی‌های این مدل کنار گذاشته می‌شوند. برای استفاده از کرایه نیز باید مبلغی با زمان دسترسیِ تأییدشده در لحظهٔ درخواست داشت. ستون کرایهٔ ثبت‌شدهٔ سفر به‌تنهایی این شرط را اثبات نمی‌کند.

تقسیم داده و سابقهٔ زمانی. واحد جداسازی، بازهٔ پیوسته بر اساس `request_datetime` است. آموزش از بازهٔ قدیمی‌تر، اعتبارسنجی از بازهٔ بعد و آزمون از بازهٔ جدیدتر تشکیل می‌شود. برش‌ها پیش از برازش تعیین می‌شوند. در مرز پایان آموزش، تنها سفرهایی وارد برازش می‌شوند که مسافرشان پیش از آن مرز سوار شده و برچسب انتظارشان معلوم شده باشد. اگر ویژگیِ «انتظار سفرهای اخیر ناحیه» ساخته شود، در هر درخواست فقط سفرهایی استفاده می‌شوند که برچسبشان تا همان لحظه در دسترس بوده است.

آمار آموزشی و آزمون نهایی. میانه‌های خط مبنا و هر مقدارِ آموخته‌شده برای جایگذاری دادهٔ خالی یا تعیین آستانهٔ پرت، از مجموعهٔ آموزش محاسبه می‌شوند. همان قواعد روی دوره‌های بعد اعمال می‌شوند. انتخاب مدل و تنظیمات بر اساس اعتبارسنجی انجام می‌شود و آزمون نهایی پس از تثبیت انتخاب‌ها به کار می‌رود. چون تحلیل اکتشافی فعلی هر دو سال را پوشش داده، ارزیابی روی همین داده‌ها نقش ارزیابی اولیه دارد. برای آزمون نهایی مستقل، یک دورهٔ زمانیِ بعدی که هنوز بررسی نشده است کنار گذاشته می‌شود.

مرجع قواعد برازش و جلوگیری از نشت، scikit-learn

8 تعریف خط مبنا

خط مبنا از الگوی زمان انتظار در سال قبل استفاده می‌کند. برای هر درخواست، ماه و ساعت از `request_datetime` استخراج می‌شود. پیش‌بینی برابر میانهٔ وزن‌دار انتظار سفرهای دارای برچسب معتبر در همان ماه و ساعتِ سال قبل است. در ارزیابی اولیهٔ فعلی، درخواست‌های سال 2025 با استفاده از دادهٔ سال 2024 پیش‌بینی می‌شوند.

میانه‌ها پیش از شروع سال هدف محاسبه می‌شوند و فقط سفرهایی در محاسبه وارد می‌شوند که زمان انتظارشان تا آن موقع معلوم شده باشد. اگر گروه متناظر دادهٔ معتبر نداشت، میانهٔ کل سال قبل جایگزین می‌شود.

مدل اصلی و خط مبنا با یک مرز زمانی برای دسترسی به اطلاعات، روی درخواست‌های یکسان ارزیابی می‌شوند. معیار مقایسه، میانگین وزن‌دار قدرمطلق خطا، MAE، بر حسب دقیقه است. کاهش این خطا نشان می‌دهد مدل اصلی نسبت به استفاده از الگوی سال قبل، پیش‌بینی بهتری ارائه می‌دهد.

9 سه سؤال اولیه و انتخاب سؤال نهایی

9.1 تخصیص رانندگان میان ناحیه‌ها

آیا در بازه‌های زمانی یکسان، دریافتی راننده به‌ازای هر سفر یا زمان انتظار مسافر در ناحیه‌های مختلف تفاوت معناداری دارد؟ برای مقایسهٔ دریافتی و کرایهٔ پایه، سفرهایی با مدت، مسافت و سرویس مشابه را بررسی می‌کنیم. فرضیه این است که توزیع نامتوازن رانندگان می‌تواند با کرایهٔ بالاتر یا انتظار طولانی‌تر همراه باشد. سنجش درآمد ساعتی یا زمان بیکاری رانندگان و ارزیابی بهینگی تخصیص به دادهٔ حضور و وضعیت رانندگان نیاز دارد.

اگر اختلافی پایدار و از نظر عملی مهم دیده شود، پرسش بعدی این است که آیا یک مدل سری زمانی می‌تواند زمان و ناحیهٔ بروز آن را پیش‌بینی کند؟

9.2 فرصت افزایش سهم بازار HVFHV

آیا سرویس‌های HVFHV می‌توانند در برخی ناحیه‌ها و بازه‌های زمانی، بخشی از سفرهای تاکسی زرد را جذب کنند و سهم خود را افزایش دهند؟ برای شناسایی این فرصت‌ها، سهم سفر دو گروه بر اساس ناحیه و زمان سوارشدن مقایسه می‌شود. سپس بررسی می‌شود چه ویژگی‌هایی، مانند نوع ناحیه و ترکیب سفرها، با تفاوت سهم همراه‌اند.

در مقایسهٔ اولیه، سهم HVFHV از تقسیم تعداد سفرهای این سرویس‌ها بر مجموع سفرهای HVFHV و تاکسی زرد در همان ناحیه و بازه به دست می‌آید. ارزیابی توجیه اقتصادی و عملیاتی افزایش سهم به اطلاعات هزینه و ظرفیت خدمت‌رسانی نیاز دارد.

9.3 پیش‌بینی زمان انتظار مسافر

در لحظهٔ ثبت درخواست سفر HVFHV، با اطلاعاتی که تا همان لحظه در دسترس‌اند، زمان انتظار مسافر تا سوارشدن را با چه دقتی می‌توان پیش‌بینی کرد؟ در تحلیل مکمل، آیا پس از در نظر گرفتن زمان درخواست و سرویس، زمان انتظار میان ناحیه‌های کم‌درآمد و پردرآمد تفاوت معناداری دارد؟

دلیل انتخاب این پرسش. زمان درخواست و سوارشدن در دادهٔ اصلی ثبت شده‌اند و متغیر هدف مستقیماً از اختلاف این دو به دست می‌آید. تحلیل مکمل پس از پیوند دادهٔ درآمد ناحیه با رکوردهای سفر قابل انجام است.